

НЕЙРОННЫЕ СЕТИ В МАШИННОМ ОБУЧЕНИИ

Лекция №4
Методы оптимизации

Евгений Богатырев





Не забывайте отмечаться
и оставлять отзывы!

Содержание

1. Постановка задачи
2. Методы
 - a. Gradient Descent
 - b. Stochastic Gradient Descent (SGD)
 - c. SGD+Momentum/Nesterov
 - d. AdaGrad
 - e. RMSProp
 - f. Adam
3. Критерии остановки

Постановка задачи

1. Надо найти оптимальные веса $\theta_* = \min_{\theta} J(\theta)$
2. В любой точке можем вычислить $\nabla_{\theta} J(\theta)$




Gradient Descent


Градиентный спуск:

$$\theta_t = \theta_{t-1} - \eta \sum_{i=1}^N \nabla_{\theta} J_i(\theta_{t-1})$$

- Требуется обработать весь датасет для одного шага
- Нет режима online обучения
- Гарантируется сходимость к (локальному) минимуму при правильном выборе шага



Back propagation



Stochastic Gradient Descent (SGD)

Полная функция потерь:


$$J(\theta) = \sum_{i=1}^N J_i(\theta)$$

Gradient Descent:

$$\theta_t = \theta_{t-1} - \eta \sum_{i=1}^N \nabla_{\theta} J_i(\theta_{t-1})$$


(Mini-Batch) Stochastic Gradient Descent:

$$\theta_t = \theta_{t-1} - \eta \sum_{i_1, \dots, i_k} \nabla_{\theta} J_i(\theta_{t-1})$$



SGD c batch_size=1


Проблемы SGD




Разное поведение
у весов

<https://distill.pub/2017/momentum/>

Проблемы SGD

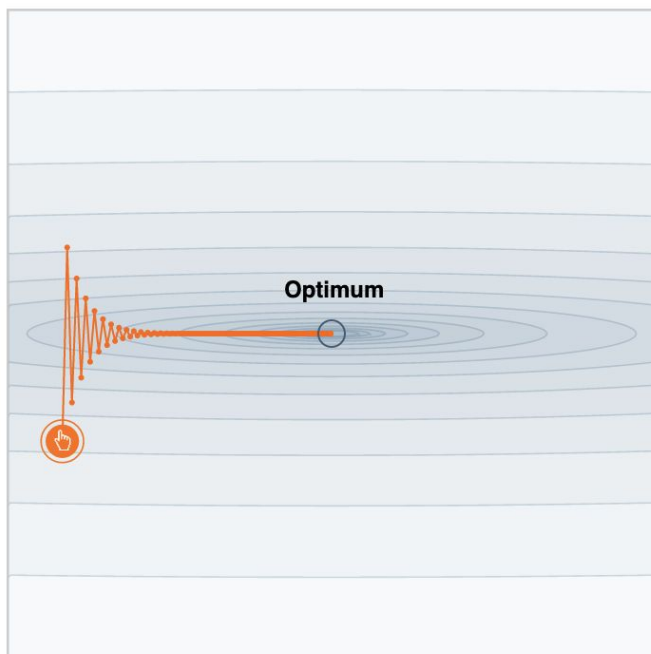


Разное поведение
у весов



Локальные минимумы и
седловые точки


Проблемы SGD



Разное поведение
у весов



Локальные минимумы и
седловые точки



Шумная функция
потерь



SGD + Momentum

Попробуем сохранять “инерцию”:


$$\nu_t = \gamma \nu_{t-1} + \eta_t \nabla_{\theta} J(\theta_{t-1})$$

$$\theta_t = \theta_{t-1} - \nu_t$$

Рекомендовано брать: $\gamma = 0.9$



SGD



SGD with momentum

SGD + Momentum


Попробуем сохранять “инерцию”:

$$\nu_t = \gamma \nu_{t-1} + \eta_t \nabla_{\theta} J(\theta_{t-1})$$


$$\theta_t = \theta_{t-1} - \nu_t$$

Рекомендовано брать: $\gamma = 0.9$

Какая проблема этого метода?



SGD



SGD with momentum

SGD + Momentum

Попробуем сохранять “инерцию”:


$$\nu_t = \gamma \nu_{t-1} + \eta_t \nabla_{\theta} J(\theta_{t-1})$$

$$\theta_t = \theta_{t-1} - \nu_t$$


Рекомендовано брать: $\gamma = 0.9$

Какая проблема этого метода?

→ Может перескакивать локальные минимумы



SGD



SGD with momentum


Nesterov accelerated gradient

Сдвигаемся на момент до вычисления градиента:


$$\nu_t = \gamma \nu_{t-1} + \eta_t \nabla_{\theta} J(\theta_{t-1} - \gamma \nu_{t-1})$$

Вычисление градиента в новой точке дает возможность скорректировать направление движения:

$$\theta_t = \theta_{t-1} - \nu_t$$



simple momentum



Nesterov momentum

AdaGrad

Градиент на шаге t :

$$g_t = \nabla_{\theta} J(\theta)$$

Сумма квадратов градиентов:

$$G_t = \sum_{k=0}^t g_k^2$$

Обновление весов:

$$\theta_{t+1} = \theta_t - \frac{\eta}{\sqrt{G_t + \epsilon}} \cdot g_t$$

Стандартные значения:

$$\eta = 0.01, \epsilon = 10^{-8}$$

AdaGrad

Градиент на шаге t :

$$g_t = \nabla_{\theta} J(\theta)$$

Сумма квадратов градиентов:

$$G_t = \sum_{k=0}^t g_k^2$$

Обновление весов:

$$\theta_{t+1} = \theta_t - \frac{\eta}{\sqrt{G_t + \epsilon}} \cdot g_t$$

Стандартные значения:

$$\eta = 0.01, \epsilon = 10^{-8}$$

Мотивация: уменьшаем learning rate для активных параметров

Какая проблема этого метода?

AdaGrad

Градиент на шаге t :

$$g_t = \nabla_{\theta} J(\theta)$$

Сумма квадратов градиентов:

$$G_t = \sum_{k=0}^t g_k^2$$

Обновление весов:

$$\theta_{t+1} = \theta_t - \frac{\eta}{\sqrt{G_t + \epsilon}} \cdot g_t$$

Стандартные значения:

$$\eta = 0.01, \epsilon = 10^{-8}$$

Мотивация: уменьшаем learning rate
для активных параметров

Какая проблема этого метода?

→ Не убывает => затухание обновлений

RMSProp

Будем использовать только последние несколько значений для подсчета

Экспоненциальное среднее:

$$G_t = \gamma G_{t-1} + (1 - \gamma) g_t^2$$

Обновление весов:

$$\theta_{t+1} = \theta_t - \frac{\eta}{\sqrt{G_t + \epsilon}} \cdot g_t$$

Adadelta



RMSProp + избавимся от learning rate

$$\Delta\theta_t = \frac{RMS[\Delta\theta]_{t-1}}{RMS[g]_t} g_t$$

Обновление весов:

$$\theta_t = \theta_{t-1} - \Delta\theta_t$$

Сравнение методов



Adaptive Moment Estimation (Adam)

Объединим лучшие идеи

Момент и затухание:

$$\begin{cases} m_t = \beta_1 m_{t-1} + (1 - \beta_1) g_t \\ \nu_t = \beta_2 \nu_{t-1} + (1 - \beta_2) g_t^2 \end{cases}$$

Обновление весов:

$$\theta_{t+1} = \theta_t - \frac{\eta}{\sqrt{\hat{\nu}_t} + \epsilon} \hat{m}_t$$

Adaptive Moment Estimation (Adam)

Объединим лучшие идеи

Момент и затухание:

$$\begin{cases} m_t = \beta_1 m_{t-1} + (1 - \beta_1) g_t \\ \nu_t = \beta_2 \nu_{t-1} + (1 - \beta_2) g_t^2 \end{cases}$$

Обновление весов:

$$\theta_{t+1} = \theta_t - \frac{\eta}{\sqrt{\hat{\nu}_t} + \epsilon} \hat{m}_t$$

Инициализируем средние нулями,
поэтому долгий “разгон”

Хотим несмещенность:

$$\mathbb{E}[m_t] = \mathbb{E}[g_t] \mathbb{E}[v_t] = \mathbb{E}[g_t^2]$$

Adaptive Moment Estimation (Adam)

Объединим лучшие идеи

Момент и затухание:

$$\begin{cases} m_t = \beta_1 m_{t-1} + (1 - \beta_1) g_t \\ \nu_t = \beta_2 \nu_{t-1} + (1 - \beta_2) g_t^2 \end{cases}$$

Обновление весов:

$$\theta_{t+1} = \theta_t - \frac{\eta}{\sqrt{\hat{\nu}_t} + \epsilon} \hat{m}_t$$

Инициализируем средние нулями,
поэтому долгий “разгон”

Хотим несмещенность:

$$\mathbb{E}[m_t] = \mathbb{E}[g_t] \mathbb{E}[v_t] = \mathbb{E}[g_t^2]$$

Делаем поправку

$$\begin{cases} \hat{m}_t = \frac{m_t}{1 - \beta_1^t} \\ \hat{\nu}_t = \frac{\nu_t}{1 - \beta_2^t} \end{cases}$$

Критерии остановки

Когда остановить обучение?



Критерии остановки

Когда остановить обучение?


- Превышен лимит по числу итераций или времени
- Качество на валидации начало ухудшаться
- $J(\theta_t) - J(\theta_*) \leq \epsilon$
- $J(\theta_t) \leq \epsilon J(\theta_0)$
- $\|\nabla J(\theta_t)\| \leq \epsilon \|\nabla J(\theta_0)\|$

Ландшафт функции потерь

В следующей лекции...



(a) without skip connections



(b) with skip connections

Figure 1: The loss surfaces of ResNet-56 with/without skip connections. The proposed filter normalization scheme is used to enable comparisons of sharpness/flatness between the two figures.

32nd Conference on Neural Information Processing Systems (NIPS 2018), Montréal, Canada.

Резюме

В этой лекции мы изучили:

1. В чем заключается задача оптимизации и что такое градиентный спуск
2. Как устроены различные методы оптимизации, в чем их достоинства и недостатки
3. Какие существуют критерии остановки обучения

Рекомендованные источники

1. H. Li, Z. Xu, G. Taylor, C. Studer, and T. Goldstein, “Visualizing the loss landscape of neural nets,” in *Advances in neural information processing systems*, 2018, p. 31.
[Available online](#)
2. Why Momentum Really Works – <https://distill.pub/2017/momentum/>
3. An overview of gradient descent optimization algorithms –
<https://www.ruder.io/optimizing-gradient-descent/>
4. Neural Networks for Machine Learning –
<https://www.cs.toronto.edu/~hinton/coursera/lecture6/lec6.pdf>

Спасибо!

На семинаре будем сравнивать
различные методы
оптимизации:



Epoch: 0/100

